



UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO II – TECNOLOGIA EM BANCO DADOS

Classificação Automatizada de Reviews da Steam com Processamento de Linguagem Natural e Machine Learning

Nome da Empresa: GameInsight Studios

Nome do Grupo: Hash

Integrantes:

- Marcos Costa Lima Araujo – RA: 10746213
- Francisco Freitas Dantas – RA: 10752131
- Leonardo Gaspar Saheb – RA: 10402213
- André Cardoso Ramires - RA: 10752544

SÃO PAULO – SP

2026



Sumário

1. PREMISSAS DO PROJETO.....	3
1.1. Apresentação da Organização.....	3
1.2. Área de Atuação e Problema de Negócio (GAP).....	3
1.3. Apresentação dos Dados.....	4
1.4. Metadados.....	4
2. OBJETIVOS E METAS.....	5
2.1. Objetivo Geral.....	5
2.2. Objetivos Específicos.....	5
2.3. Metas do Projeto.....	5
3. CRONOGRAMA DE ATIVIDADES.....	6
4. DESENVOLVIMENTO E METODOLOGIA.....	7
4.1. Definição das Bibliotecas Python.....	7
4.2. Análise Exploratória de Dados (AED).....	7
4.2.1. Caracterização da base.....	7
4.2.2. Análise das avaliações textuais.....	7
4.2.3. Definição da base de análise.....	8
4.2.4. Resumo da base.....	8
4.3. Tratamento e Preparação dos Dados.....	9
4.3.1. Limpeza e normalização.....	9
4.3.2. Preparação da variável-alvo.....	9
4.3.3. Preparação para modelagem.....	10
5. MODELAGEM E AVALIAÇÃO.....	10
5.1. Bases Teóricas dos Métodos Analíticos.....	10
5.1.1. TF-IDF.....	10
5.1.2. Classificação supervisionada.....	10
5.1.3. Multinomial Naive Bayes.....	11
5.1.4. Regressão Logística.....	11
5.1.5. Random Forest.....	11
5.1.6. Aplicação dos métodos.....	11
5.2. Cálculo da Acurácia e Métricas de Avaliação.....	12
5.2.1. Treinamento e previsão.....	12
5.2.2. Acurácia e avaliação.....	12
5.2.3. Matriz de confusão.....	12
5.2.4. Avaliação por classe.....	13
5.2.5. Comparação dos resultados.....	13
6. REPOSITÓRIO DO PROJETO.....	14
7. CONSIDERAÇÕES FINAIS.....	14
8. REFERÊNCIAS.....	16



1. PREMISSAS DO PROJETO

1.1. Apresentação da Organização

A **GameInsight Studios** é uma empresa fictícia criada para este projeto, voltada à análise de dados no mercado de jogos eletrônicos. A empresa utiliza informações e opiniões dos jogadores para entender melhor a experiência dos usuários e apoiar decisões relacionadas aos seus produtos.

O objetivo deste projeto é analisar avaliações de jogadores disponíveis na Steam, utilizando técnicas de análise de dados, Processamento de Linguagem Natural (NLP) e Machine Learning, a fim de identificar padrões nas opiniões dos usuários, classificar sentimentos e extrair informações que possam contribuir para a compreensão da experiência dos jogadores.

Para este projeto, serão utilizadas avaliações públicas de usuários da Steam. Esses dados são analisados com técnicas de análise de dados, Processamento de Linguagem Natural (NLP) e Machine Learning.

A Steam será utilizada somente como fonte dos dados. O projeto não representa uma solução desenvolvida para a Steam ou uma parceria com a Valve Corporation. A análise será realizada de forma independente e com finalidade acadêmica.

1.2. Área de Atuação e Problema de Negócio (GAP)

A GameInsight Studios atua na área de análise de dados aplicada ao mercado de jogos eletrônicos, com foco na experiência dos jogadores, enfrentando o desafio de processar a enorme quantidade de avaliações dos usuários. Como esses comentários são em texto livre, a análise manual exige muito tempo, dificultando a identificação ágil das principais opiniões do público. Diante desse cenário, o projeto utiliza esses dados para identificar automaticamente se os usuários recomendam os jogos, analisando os textos em busca de padrões que ajudem na compreensão clara e estruturada da opinião dos jogadores.



1.3. Apresentação dos Dados

Os dados utilizados são avaliações de usuários da **Steam**, compostas principalmente por textos livres. A base utilizada pelo grupo foi obtida a partir do **Steam Dataset 2025**.

Após a seleção e preparação inicial dos dados, foi definido um recorte com **19.487 avaliações**, considerando avaliações em **inglês** realizadas entre **2010 e 2025**. A coluna **review** contém o texto escrito pelo usuário e foi utilizada como principal fonte para a análise. A coluna **voted_up** indica se o usuário recomendou ou não o jogo

- 19.487 avaliações foram selecionadas inicialmente;
- 262 avaliações ficaram sem conteúdo após a limpeza dos textos e foram removidas da base de modelagem;
- A base utilizada na modelagem ficou composta por 19.225 avaliações;
- 14.391 avaliações (74,86%) são recomendações positivas;
- 4.834 avaliações (25,14%) são recomendações negativas;
- Não foram encontradas avaliações duplicadas na base utilizada.

1.4. Metadados

Campo	Descrição	Uso no projeto
review	Texto escrito pelo usuário	Análise dos textos
voted_up	Indica se o jogo foi recomendado	Classificação das avaliações
language	Idioma da avaliação	Seleção das avaliações em inglês
timestamp_created	Data de criação da avaliação	Análise do período
votes_up	Quantidade de votos	Informação auxiliar
steam_purchase	indica relação com a compra	Informação auxiliar



A coluna review será utilizada como principal fonte para as análises de texto. A coluna voted_up será utilizada como referência para a classificação entre recomendações positivas e negativas

2. OBJETIVOS E METAS

2.1. Objetivo Geral

Desenvolver uma solução para analisar e classificar avaliações de usuários da Steam, utilizando técnicas de Processamento de Linguagem Natural (NLP) e Machine Learning, com o objetivo de identificar recomendações positivas e negativas e facilitar a análise da opinião dos jogadores.

2.2. Objetivos Específicos

- Preparar e organizar os textos das avaliações para a análise;
- Realizar o tratamento dos dados textuais, incluindo a limpeza e normalização dos textos;
- Transformar os textos em dados que possam ser utilizados pelos modelos de classificação;
- Testar e comparar modelos de Machine Learning para classificar as avaliações ;
- Avaliar o desempenho dos modelos utilizando métricas como Acurácia, Precisão, Recall e F1-Score;
- Analisar os resultados obtidos e identificar padrões nas avaliações dos usuários;
- Organizar os resultados de forma que possam auxiliar na compreensão da opinião dos jogadores.

2.3. Metas do Projeto

- Preparar uma base de avaliações adequada para as etapas de análise e modelagem;
- Desenvolver um processo de classificação das avaliações entre recomendações positivas e negativas;
- Comparar o desempenho dos modelos utilizados;



- Buscar F1-Score de pelo menos 80% no modelo selecionado.
- Documentar todas as etapas realizadas e disponibilizar o código e os resultados no repositório do projeto.

3. CRONOGRAMA DE ATIVIDADES

O cronograma foi elaborado considerando as principais atividades previstas para o desenvolvimento do Projeto Aplicado II. As atividades estão distribuídas ao longo das quatro etapas do projeto, desde a definição e preparação dos dados até a análise dos resultados e apresentação final.

Etapas	Atividades principais	Período
Etapa 1 - Definição do Projeto	Definição do problema, organização, dados, objetivos, metas e planejamento.	20/08/2026 a 28/08/2026
Etapa 2 - Análise Exploratória	Preparação dos dados, análise exploratória, tratamento dos textos, aplicação de NLP e avaliação inicial dos modelos.	20/09/2026 a 25/09/2026
Etapa 3 - Modelagem	Aprofundamento da modelagem, análise dos resultados e possíveis ajustes nos modelos.	15/10/2026 a 23/10/2026
Etapa 4 - Consolidação	Avaliação final dos resultados, organização das conclusões e preparação da apresentação final.	10/11/2026 a 20/11/2026



4. DESENVOLVIMENTO E METODOLOGIA

4.1. Definição das Bibliotecas Python

- **pandas:** leitura, organização e análise dos dados;
- **numpy:** operações e manipulação de dados numéricos;
- **scikit-learn:** preparação dos dados, TF-IDF, treinamento dos modelos e cálculo das métricas;
- **matplotlib:** criação dos gráficos;
- **seaborn:** visualização das matrizes de confusão;
- **gzip:** leitura do arquivo JSON compactado;
- **json:** leitura e manipulação dos dados em formato JSON;
- **pathlib:** definição dos caminhos dos arquivos;
- **re:** limpeza e normalização dos textos.

4.2. Análise Exploratória de Dados (AED)


4.2.1. Caracterização da base

A base utilizada no projeto é composta por avaliações públicas de usuários da Steam. Inicialmente, foram analisadas a estrutura dos dados, a distribuição das recomendações, os idiomas disponíveis e o período das avaliações. Essa etapa permitiu compreender as principais características da base e identificar os recortes necessários para definir o conjunto de dados utilizado nas etapas posteriores.

4.2.2. Análise das avaliações textuais

Foi analisado o tamanho das avaliações por meio da quantidade de palavras presentes em cada texto. Essa análise permitiu identificar a extensão das opiniões dos usuários e observar a existência de avaliações muito curtas. Neste momento, os textos não foram removidos, pois a análise teve como objetivo apenas compreender as características das avaliações e auxiliar nas decisões das etapas posteriores de preparação dos dados.

Figura 1: Distribuição da quantidade de palavras nas avaliações textuais



4.2.3. Definição da base de análise

Após a análise inicial, foi definido o recorte utilizado no projeto, considerando exclusivamente as avaliações em inglês disponíveis entre os anos de 2010 e 2025. Esse período foi mantido por abranger todo o intervalo temporal selecionado na base e permitir a utilização de uma quantidade maior de avaliações para as etapas de análise e modelagem.

4.2.4. Resumo da base

Após os processos de seleção e validação, foram selecionadas 19.487 avaliações em inglês, abrangendo o período de 2010 a 2025. A variável **voted_up** foi utilizada para identificar as recomendações positivas e negativas dos usuários, servindo como variável-alvo para os modelos de classificação. Após a limpeza dos textos, 262 avaliações ficaram sem conteúdo e foram removidas. Dessa forma, a base final utilizada na modelagem ficou composta por 19.225 avaliações.


4.3. Tratamento e Preparação dos Dados

4.3.1. Limpeza e normalização

As avaliações textuais passaram por um processo de limpeza e normalização para padronizar os dados utilizados na modelagem. Os textos foram convertidos para letras minúsculas e foram removidas URLs, caracteres desnecessários e espaços extras. As stopwords não foram removidas nesta etapa, pois algumas palavras podem contribuir para a identificação do sentimento ou da recomendação presente nas avaliações.

4.3.2. Preparação da variável-alvo

A variável **voted_up**, responsável por indicar se o usuário recomendou o jogo, foi utilizada como variável-alvo dos modelos de classificação. Para facilitar o processamento, os valores foram convertidos para uma representação numérica, em que **1** corresponde a uma recomendação positiva e **0** a uma recomendação negativa. Após a limpeza dos textos, a base utilizada na modelagem ficou composta por 19.225 avaliações, sendo 14.391 positivas (74,86%) e 4.834 negativas (25,14%).





4.3.3. Preparação para modelagem

Após as etapas de limpeza, os dados foram organizados para a aplicação dos métodos de classificação. A variável **review_limpa** passou a representar o conteúdo textual utilizado como entrada dos modelos, enquanto a variável alvo representa a classe a ser prevista. Também foram removidas 262 avaliações que ficaram sem conteúdo após a limpeza, resultando em 19.225 registros disponíveis para as etapas de vetorização e modelagem.

5. MODELAGEM E AVALIAÇÃO

5.1. Bases Teóricas dos Métodos Analíticos

5.1.1. TF-IDF

Para transformar as avaliações textuais em dados que possam ser utilizados pelos modelos de classificação, foi aplicada a técnica TF-IDF (Term Frequency-Inverse Document Frequency). O método atribui pesos aos termos de acordo com sua frequência e relevância nos documentos, permitindo representar os textos numericamente. No projeto, foram consideradas palavras individuais e combinações de duas palavras, com limite de 5.000 características, e a vetorização foi ajustada somente sobre os dados de treinamento para evitar o uso de informações do conjunto de testes.

5.1.2. Classificação supervisionada

O projeto utiliza classificação supervisionada, na qual os modelos aprendem a partir de dados que possuem uma variável-alvo conhecida. Neste caso, as avaliações textuais representam os dados de entrada e a variável **voted_up**, posteriormente convertida para 0 e 1, representa a classe a ser prevista. Foram selecionados três modelos para identificar se uma avaliação corresponde a uma recomendação positiva ou negativa: Multinomial Naive Bayes, Regressão Logística e Random Forest.



5.1.3. Multinomial Naive Bayes

O Multinomial Naive Bayes é um modelo probabilístico de classificação que pode ser aplicado a dados textuais. Seu funcionamento considera a ocorrência das características presentes nos documentos para estimar a probabilidade de cada avaliação pertencer a determinada classe. Neste projeto, o modelo foi aplicado sobre a representação TF-IDF das avaliações para realizar a classificação entre recomendações positivas e negativas.

5.1.4. Regressão Logística

A Regressão Logística é um método de classificação utilizado para estimar a probabilidade de um registro pertencer a determinada classe. No projeto, o modelo recebe como entrada os valores gerados pela vetorização TF-IDF e utiliza essas características para classificar as avaliações como recomendações positivas ou negativas. Sua utilização permite avaliar uma abordagem linear para o problema de classificação dos textos.

5.1.5. Random Forest

O Random Forest é um método de classificação baseado na combinação de diversas árvores de decisão. Cada árvore realiza uma classificação a partir dos dados disponíveis e os resultados são combinados para definir a previsão final. Neste projeto, o método foi utilizado sobre os dados vetorizados pelo TF-IDF, permitindo comparar uma abordagem baseada em árvores com os modelos probabilístico e linear.

5.1.6. Aplicação dos métodos

Após a preparação dos textos e a vetorização por TF-IDF, os três modelos selecionados foram treinados utilizando o conjunto de dados de treinamento. Em seguida, foram realizadas previsões sobre o conjunto de teste, mantendo os dados de teste separados durante o treinamento.



Dessa forma, foi possível utilizar o mesmo conjunto de avaliação para comparar o desempenho do Multinomial Naive Bayes, da Regressão Logística e do Random Forest. Os dados foram divididos em 80% para treinamento e 20% para teste. Foi utilizada estratificação para manter a proporção das classes nos dois conjuntos, com **random_state** definido como 42.

5.2. Cálculo da Acurácia e Métricas de Avaliação

5.2.1. Treinamento e previsão

Os modelos Multinomial Naive Bayes, Regressão Logística e Random Forest foram treinados utilizando os dados de treinamento previamente preparados e vetorizados pelo TF-IDF. Após o treinamento, cada modelo realizou previsões sobre o conjunto de teste, permitindo calcular as métricas de desempenho e analisar a capacidade de classificação das avaliações entre recomendações positivas e negativas.

5.2.2. Acurácia e avaliação


A acurácia foi utilizada para verificar a proporção de classificações corretas realizadas por cada modelo. Os resultados obtidos foram de 84,08% para o Multinomial Naive Bayes, 86,29% para a Regressão Logística e 82,89% para o Random Forest. Além da acurácia, foram analisadas precisão, recall e F1-Score, permitindo uma avaliação mais completa do comportamento dos modelos.

5.2.3. Matriz de confusão

As matrizes de confusão permitiram analisar os acertos e erros dos três modelos nas classificações das avaliações positivas e negativas. No Multinomial Naive Bayes, foram identificados 397 verdadeiros negativos, 570 falsos positivos, 42 falsos negativos e 2.836 verdadeiros positivos. Na Regressão Logística, foram obtidos 549 verdadeiros negativos, 418 falsos positivos, 109 falsos negativos e 2.769 verdadeiros positivos. Já o Random Forest apresentou 381 verdadeiros negativos, 586 falsos

positivos, 72 falsos negativos e 2.806 verdadeiros positivos. Os resultados mostram que os três modelos apresentaram maior quantidade de acertos na classificação das avaliações positivas, enquanto os erros de classificação da classe negativa foram mais frequentes.

Figura 3: Matrizes de Confusão dos Modelos Avaliados



5.2.4. Avaliação por classe


A avaliação por classe permitiu analisar separadamente o desempenho dos modelos na identificação das recomendações negativas e positivas. Os resultados mostram que os três modelos apresentaram maior capacidade de identificação da classe positiva, com recall de 98,54% no Multinomial Naive Bayes, 96,21% na Regressão Logística e 97,50% no Random Forest. Para a classe negativa, os recalls foram menores, sendo 41,05% no Multinomial Naive Bayes, 56,77% na Regressão Logística e 39,40% no Random Forest, indicando maior dificuldade dos modelos em identificar corretamente as avaliações negativas.

5.2.5. Comparação dos resultados

Os três modelos apresentaram resultados diferentes na classificação das avaliações. A Regressão Logística apresentou acurácia de 86,29% e F1-Score de 91,31%. O Multinomial Naive Bayes apresentou acurácia de 84,08% e F1-Score de 90,26%, enquanto o Random Forest apresentou acurácia de 82,89% e F1-Score de 89,51%. Os resultados também mostram diferenças na identificação das classes. A classe positiva

apresentou maior recall nos três modelos, enquanto a classe negativa apresentou valores menores. Essa diferença está relacionada à distribuição das classes na base utilizada para a modelagem.

Figura 4: Comparação de Desempenho dos Modelos



6. REPOSITÓRIO DO PROJETO

O desenvolvimento do projeto será realizado de forma colaborativa e os arquivos utilizados serão mantidos em um repositório no GitHub. O repositório contém os notebooks, códigos e demais arquivos utilizados durante o desenvolvimento do projeto.

Repositório: [Projeto Classificações das Avaliações](#)

7. CONSIDERAÇÕES FINAIS

Até o momento, o projeto avançou desde a definição do problema e da base de dados até a aplicação de técnicas de Processamento de Linguagem Natural (NLP) e Machine Learning para a classificação das avaliações da Steam.

A partir da seleção inicial dos dados, foi realizada a Análise Exploratória de Dados (AED), seguida pelo tratamento e normalização dos textos. Após a limpeza, foram removidas 262 avaliações que ficaram sem conteúdo textual,



resultando em uma base de 19.225 avaliações utilizadas na modelagem, sendo 74,86% positivas e 25,14% negativas.

Os textos foram transformados em dados numéricos por meio da técnica TF-IDF e utilizados no treinamento de três modelos de classificação: Multinomial Naive Bayes, Regressão Logística e Random Forest. A avaliação foi realizada utilizando Acurácia, Precisão, Recall e F1-Score, além das matrizes de confusão.

Os resultados apresentaram diferenças entre os modelos e entre as classes analisadas. A classe positiva apresentou maior capacidade de identificação, enquanto a classe negativa apresentou recalls menores nos três modelos. Esse comportamento deve ser considerado na interpretação dos resultados, principalmente devido à diferença na distribuição das classes da base.

Para as próximas etapas, será realizada a continuidade da análise dos resultados, o aprofundamento da avaliação dos modelos e a organização das conclusões finais do projeto.



8. REFERÊNCIAS

VINTAGEDON. Steam Dataset 2025: Multi-Modal Gaming Analytics Platform. GitHub Repository, 2025. Disponível em: https://github.com/vintagedon/steam-dataset-2025/data/01_raw_at_main. Acesso em: 26 ago. 2026.

VALVE CORPORATION. Steam Community and Platform Overview. Valve, 2026. Disponível em: <https://store.steampowered.com>. Acesso em: 26 ago. 2026.

GOOGLE CLOUD. O que é Machine Learning?. Google Cloud, 2026. Disponível em: <https://cloud.google.com/learn/what-is-machine-learning?hl=pt-BR>. Acesso em: 26 ago. 2026.