



UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO II – TECNOLOGIA EM BANCO DADOS

Classificação Automatizada de Reviews da Steam com Processamento de Linguagem Natural e Machine Learning

Nome da Empresa: GameInsight Studios

Nome do Grupo: Hash

Integrantes:

- Marcos Costa Lima Araujo – RA: 10746213
- Francisco Freitas Dantas – RA: 10752131
- Leonardo Gaspar Saheb – RA: 10402213
- André Cardoso Ramires - RA: 10752544

SÃO PAULO – SP

2026



Sumário

1. PREMISSAS DO PROJETO.....	3
1.1. Apresentação da Organização.....	3
1.2. Área de Atuação e Problema de Negócio (GAP).....	3
1.3. Apresentação dos Dados.....	4
1.4. Metadados.....	4
2. OBJETIVOS E METAS.....	5
2.1. Objetivo Geral.....	5
2.2. Objetivos Específicos.....	5
2.3. Metas do Projeto.....	5
3. CRONOGRAMA DE ATIVIDADES.....	6
4. REPOSITÓRIO DO PROJETO.....	7
5. CONSIDERAÇÕES FINAIS.....	7
6. REFERÊNCIAS.....	8



1. PREMISSAS DO PROJETO

1.1. Apresentação da Organização

A **GameInsight Studios** é uma empresa fictícia criada para este projeto, voltada à análise de dados no mercado de jogos eletrônicos. A empresa utiliza informações e opiniões dos jogadores para entender melhor a experiência dos usuários e apoiar decisões relacionadas aos seus produtos.

Para este projeto, serão utilizadas avaliações públicas de usuários da Steam. Esses dados serão analisados com técnicas de análise de dados, Processamento de Linguagem Natural (NLP) e, nas etapas seguintes, Machine Learning.

A Steam será utilizada somente como fonte dos dados. O projeto não representa uma solução desenvolvida para a Steam ou uma parceria com a Valve Corporation. A análise será realizada de forma independente e com finalidade acadêmica.

1.2. Área de Atuação e Problema de Negócio (GAP)

A GameInsight Studios atua na área de análise de dados aplicada ao mercado de jogos eletrônicos, com foco na experiência dos jogadores.

Um dos problemas nesse setor é a grande quantidade de avaliações escritas pelos usuários. Como os comentários são textos livres, a análise manual de todas as avaliações pode levar muito tempo e dificultar a identificação das principais opiniões dos jogadores.

O projeto busca utilizar os dados dessas avaliações para identificar se os usuários recomendam ou não os jogos e, nas etapas seguintes, analisar os textos para encontrar padrões que possam ajudar na compreensão da opinião dos jogadores.



1.3. Apresentação dos Dados

Os dados utilizados são avaliações de usuários da **Steam**, compostas principalmente por textos livres. A base utilizada pelo grupo foi obtida a partir do **Steam Dataset 2025**.

Após a seleção e preparação inicial dos dados, foi definido um recorte com **18.290 avaliações**, considerando avaliações em **inglês** realizadas entre **2010 e 2025**. A coluna **review** contém o texto escrito pelo usuário e será a principal informação utilizada na análise. A coluna **voted_up** indica se o usuário recomendou ou não o jogo

- **13.887 avaliações (75,93%)** são recomendações positivas;
- **4.403 avaliações (24,07%)** são recomendações negativas;
- Não foram encontradas avaliações duplicadas;
- A média é de aproximadamente **77 palavras por avaliação**.

1.4. Metadados

Campo	Descrição	Uso no projeto
review	Texto escrito pelo usuário	Análise dos textos
voted_up	Indica se o jogo foi recomendado	Classificação das avaliações
language	Idioma da avaliação	Seleção das avaliações em inglês
timestamp_created	Data de criação da avaliação	Análise do período
votes_up	Quantidade de votos	Informação auxiliar
steam_purchase	indica relação com a compra	Informação auxiliar

A coluna review será utilizada como principal fonte para as análises de texto. A coluna voted_up será utilizada como referência para a classificação entre recomendações positivas e negativas



2. OBJETIVOS E METAS

2.1. Objetivo Geral

Desenvolver uma solução para analisar e classificar avaliações de usuários da Steam, utilizando técnicas de Processamento de Linguagem Natural (NLP) e Machine Learning, com o objetivo de identificar recomendações positivas e negativas e facilitar a análise da opinião dos jogadores.

2.2. Objetivos Específicos

- Preparar e organizar os textos das avaliações para a análise;
- Realizar o tratamento dos dados textuais, incluindo a limpeza e normalização dos textos;
- Transformar os textos em dados que possam ser utilizados pelos modelos de classificação;
- Testar e comparar modelos de Machine Learning para classificar as avaliações ;
- Avaliar o desempenho dos modelos utilizando métricas como Acurácia, Precisão, Recall e F1-Score;
- Analisar os resultados obtidos e identificar padrões nas avaliações dos usuários;
- Organizar os resultados de forma que possam auxiliar na compreensão da opinião dos jogadores.

2.3. Metas do Projeto

- Preparar uma base de avaliações adequada para as etapas de análise e modelagem;
- Desenvolver um processo de classificação das avaliações entre recomendações positivas e negativas;
- Comparar o desempenho dos modelos utilizados;
- Buscar F1-Score de pelo menos 80% no modelo selecionado.



- Documentar todas as etapas realizadas e disponibilizar o código e os resultados no repositório do projeto.

3. CRONOGRAMA DE ATIVIDADES

O cronograma foi elaborado considerando as principais atividades previstas para o desenvolvimento do Projeto Aplicado II. As atividades estão distribuídas ao longo das quatro etapas do projeto, desde a definição e preparação dos dados até a análise dos resultados e apresentação final.

Etapas	Atividades principais	Período
Etapa 1 - Definição do Projeto	Definição do problema, organização, dados, objetivos, metas e planejamento.	Agosto/2026
Etapa 2 - Análise Exploratória	Preparação dos dados, análise exploratória e identificação de padrões nas avaliações.	Setembro/2026
Etapa 3 - Modelagem	Pré-processamento dos textos, aplicação de NLP e treinamento e avaliação de modelos de classificação.	Outubro/2026
Etapa 4 - Consolidação	Avaliação dos resultados, organização das conclusões e preparação da apresentação final.	Novembro/2026



4. REPOSITÓRIO DO PROJETO

O desenvolvimento do projeto será realizado de forma colaborativa e os arquivos utilizados serão mantidos em um repositório no GitHub. O repositório contém os notebooks, códigos e demais arquivos utilizados durante o desenvolvimento do projeto.

Repositório: [Projeto Classificações das Avaliações](#)

5. CONSIDERAÇÕES FINAIS

Nesta primeira etapa, foram definidos o grupo, a organização, o problema a ser analisado e os dados que serão utilizados no projeto. Também foram estabelecidos os objetivos, as metas e o cronograma das atividades.

A preparação inicial da base permitiu definir o recorte que será utilizado nas próximas etapas, considerando avaliações em inglês realizadas entre 2010 e 2025. A partir dessa definição, o grupo poderá avançar para a análise exploratória dos dados e, posteriormente, para as etapas de processamento dos textos e classificação das avaliações.



6. REFERÊNCIAS

VINTAGEDON. Steam Dataset 2025: Multi-Modal Gaming Analytics Platform. GitHub Repository, 2025. Disponível em: https://github.com/vintagedon/steam-dataset-2025/data/01_raw_at_main . Acesso em: 26 ago. 2026.

VALVE CORPORATION. Steam Community and Platform Overview. Valve, 2026. Disponível em: <https://store.steampowered.com>. Acesso em: 26 ago. 2026.

GOOGLE CLOUD. O que é Machine Learning?. Google Cloud, 2026. Disponível em: <https://cloud.google.com/learn/what-is-machine-learning?hl=pt-BR>. Acesso em: 26 ago. 2026.