UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO II – TECNOLOGIA EM BANCO DADOS

Classificação Automatizada de Reviews da Steam com Processamento de Linguagem Natural e Machine Learning

Nome da Empresa: GameInsight Studios

Nome do Grupo: Hash

Integrantes:

- Marcos Costa Lima Araujo – RA: 10746213
- Francisco Freitas Dantas – RA: 10752131
- Leonardo Gaspar Saheb – RA: 10402213
- André Cardoso Ramires - RA: 10752544

SÃO PAULO – SP

2026

Sumário

1. PREMISSAS DO PROJETO..... 4
1.1. Apresentação da Organização..... 4
1.2. Área de Atuação e Problema de Negócio (GAP)..... 4
1.3. Apresentação dos Dados..... 5
1.4. Metadados..... 5
2. OBJETIVOS E METAS..... 6
2.1. Objetivo Geral..... 6
2.2. Objetivos Específicos..... 6
2.3. Metas do Projeto..... 6
3. CRONOGRAMA DE ATIVIDADES..... 7
4. DESENVOLVIMENTO E METODOLOGIA..... 7
4.1. Definição das Bibliotecas Python..... 7
4.2. Análise Exploratória de Dados (AED)..... 8
4.2.1. Caracterização da base..... 8
4.2.2. Análise das avaliações textuais..... 8
4.2.3. Definição da base de análise..... 9
4.2.4. Resumo da base..... 9
4.3. Tratamento e Preparação dos Dados..... 9
4.3.1. Limpeza e normalização..... 9
4.3.2. Preparação da variável-alvo..... 9
4.3.3. Preparação para modelagem..... 10
5. MODELAGEM E AVALIAÇÃO..... 10
5.1. Bases Teóricas dos Métodos Analíticos..... 10
5.1.1. TF-IDF..... 10
5.1.2. Classificação supervisionada..... 11
5.1.3. Multinomial Naive Bayes..... 11
5.1.4. Regressão Logística..... 12
5.1.5. Random Forest..... 12
5.1.6. Aplicação dos métodos..... 13
5.2. Cálculo da Acurácia e Métricas de Avaliação..... 13
5.2.1. Treinamento e previsão..... 13
5.2.2. Acurácia e avaliação..... 14
5.2.3. Matriz de confusão..... 16
5.2.4. Avaliação por classe..... 16
5.2.5. Comparação dos resultados..... 17
5.3. Produto Analítico e Modelo de Negócios..... 19
5.3.1. Descrição do Produto Analítico..... 19

5.3.2. Proposta de modelo de negócios.....20
5.4. Esboço do Storytelling..... 21
5.4.1. Contextualização do problema..... 21
5.4.2. Análise dos dados e desenvolvimento da solução..... 21
5.4.3. Principais resultados e descoberta.....21
5.4.4. Aplicação prática e próximos passos.....22
6. REPOSITÓRIO DO PROJETO..... 23
7. CONSIDERAÇÕES FINAIS..... 23
8. REFERÊNCIAS..... 24

1. PREMISSAS DO PROJETO

1.1. Apresentação da Organização

A **GameInsight Studios** é uma empresa fictícia criada para este projeto, voltada à análise de dados no mercado de jogos eletrônicos. A empresa utiliza informações e opiniões dos jogadores para entender melhor a experiência dos usuários e apoiar decisões relacionadas aos seus produtos.

O objetivo deste projeto é analisar avaliações de jogadores disponíveis na Steam, utilizando técnicas de análise de dados, Processamento de Linguagem Natural (NLP) e Machine Learning, a fim de identificar padrões nas opiniões dos usuários, classificar sentimentos e extrair informações que possam contribuir para a compreensão da experiência dos jogadores.

Para este projeto, serão utilizadas avaliações públicas de usuários da Steam. Esses dados são analisados com técnicas de análise de dados, Processamento de Linguagem Natural (NLP) e Machine Learning.

A Steam será utilizada somente como fonte dos dados. O projeto não representa uma solução desenvolvida para a Steam ou uma parceria com a Valve Corporation. A análise será realizada de forma independente e com finalidade acadêmica.

1.2. Área de Atuação e Problema de Negócio (GAP)

A GameInsight Studios atua na área de análise de dados aplicada ao mercado de jogos eletrônicos, com foco na experiência dos jogadores, enfrentando o desafio de processar a enorme quantidade de avaliações dos usuários. Como esses comentários são em texto livre, a análise manual exige muito tempo, dificultando a identificação ágil das principais opiniões do público. Diante desse cenário, o projeto utiliza esses dados para identificar automaticamente se os usuários recomendam os jogos, analisando os textos em busca de padrões que ajudem na compreensão clara e estruturada da opinião dos jogadores.

1.3. Apresentação dos Dados

Os dados utilizados são avaliações de usuários da **Steam**, compostas principalmente por textos livres. A base utilizada pelo grupo foi obtida a partir do **Steam Dataset 2025**.

Após a seleção e preparação inicial dos dados, foi definido um recorte com **19.487 avaliações**, considerando avaliações em **inglês** realizadas entre **2010 e 2025**. A coluna **review** contém o texto escrito pelo usuário e foi utilizada como principal fonte para a análise. A coluna **voted_up** indica se o usuário recomendou ou não o jogo

- 19.487 avaliações foram selecionadas inicialmente;
- 262 avaliações ficaram sem conteúdo após a limpeza dos textos e foram removidas da base de modelagem;
- A base utilizada na modelagem ficou composta por 19.225 avaliações;
- 14.391 avaliações (74,86%) são recomendações positivas;
- 4.834 avaliações (25,14%) são recomendações negativas;
- Na verificação de duplicidades textuais, foram identificados 384 registros com textos repetidos. Esses registros foram identificados na análise, mas não foram removidos automaticamente por essa verificação.

1.4. Metadados

Campo	Descrição	Uso no projeto
review	Texto escrito pelo usuário	Análise dos textos
voted_up	Indica se o jogo foi recomendado	Classificação das avaliações
language	Idioma da avaliação	Seleção das avaliações em inglês
timestamp_created	Data de criação da avaliação	Análise do período
votes_up	Quantidade de votos	Informação auxiliar
steam_purchase	indica relação com a compra	Informação auxiliar

A coluna review será utilizada como principal fonte para as análises de texto. A coluna voted_up será utilizada como referência para a classificação entre recomendações positivas e negativas

2. OBJETIVOS E METAS

2.1. Objetivo Geral

Desenvolver uma solução para analisar e classificar avaliações de usuários da Steam, utilizando técnicas de Processamento de Linguagem Natural (NLP) e Machine Learning, com o objetivo de identificar recomendações positivas e negativas e facilitar a análise da opinião dos jogadores.

2.2. Objetivos Específicos

- Preparar e organizar os textos das avaliações para a análise;
- Realizar o tratamento dos dados textuais, incluindo a limpeza e normalização dos textos;
- Transformar os textos em dados que possam ser utilizados pelos modelos de classificação;
- Testar e comparar modelos de Machine Learning para classificar as avaliações ;
- Avaliar o desempenho dos modelos utilizando métricas como Acurácia, Precisão, Recall e F1-Score;
- Analisar os resultados obtidos e identificar padrões nas avaliações dos usuários;
- Organizar os resultados de forma que possam auxiliar na compreensão da opinião dos jogadores.

2.3. Metas do Projeto

- Preparar uma base de avaliações adequada para as etapas de análise e modelagem;
- Desenvolver um processo de classificação das avaliações entre recomendações positivas e negativas;
- Comparar o desempenho dos modelos utilizados;
- Buscar F1-Score de pelo menos 80% no modelo selecionado.

- Documentar todas as etapas realizadas e disponibilizar o código e os resultados no repositório do projeto.

3. CRONOGRAMA DE ATIVIDADES

O cronograma foi elaborado considerando as principais atividades previstas para o desenvolvimento do Projeto Aplicado II. As atividades estão distribuídas ao longo das quatro etapas do projeto, desde a definição e preparação dos dados até a análise dos resultados e apresentação final.

Etapa	Atividades principais	Período
Etapa 1 - Definição do Projeto	Definição do problema, organização, dados, objetivos, metas e planejamento.	20/08/2026 a 28/08/2026
Etapa 2 - Análise Exploratória	Preparação dos dados, análise exploratória, tratamento dos textos, aplicação de NLP e avaliação inicial dos modelos.	20/09/2026 a 25/09/2026
Etapa 3 - Modelagem	Aprofundamento da modelagem, análise dos resultados e possíveis ajustes nos modelos.	15/10/2026 a 23/10/2026
Etapa 4 - Consolidação	Avaliação final dos resultados, organização das conclusões e preparação da apresentação final.	10/11/2026 a 20/11/2026

4. DESENVOLVIMENTO E METODOLOGIA

4.1. Definição das Bibliotecas Python

- **pandas:** leitura, organização e análise dos dados;
- **numpy:** operações e manipulação de dados numéricos;
- **scikit-learn:** preparação dos dados, TF-IDF, treinamento dos modelos e cálculo das métricas;
- **matplotlib:** criação dos gráficos;
- **seaborn:** visualização das matrizes de confusão;
- **gzip:** leitura do arquivo JSON compactado;
- **json:** leitura e manipulação dos dados em formato JSON;
- **pathlib:** definição dos caminhos dos arquivos;
- **re:** limpeza e normalização dos textos.

4.2. Análise Exploratória de Dados (AED)

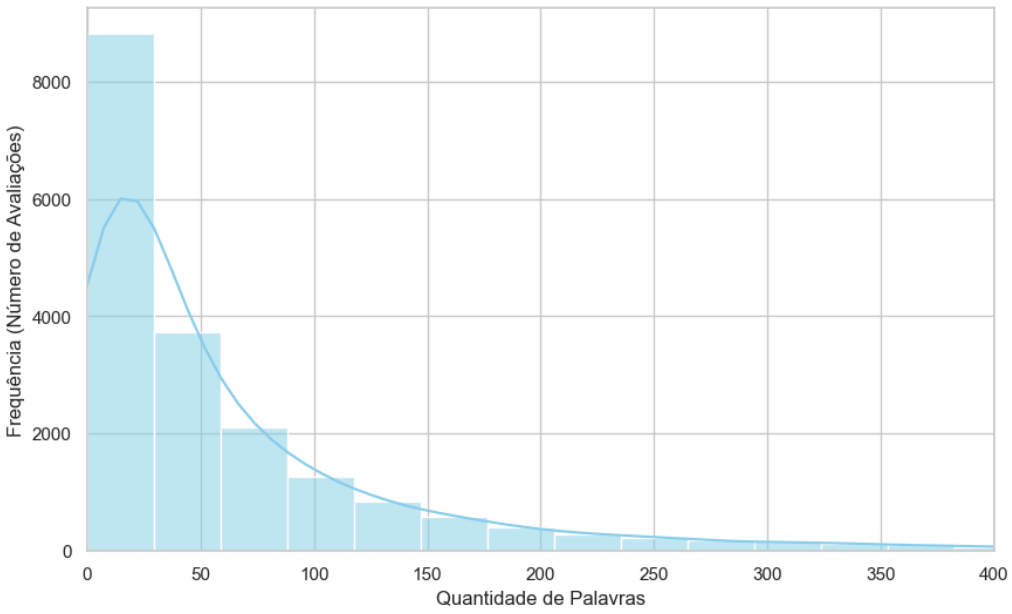
4.2.1. Caracterização da base

A base utilizada no projeto é composta por avaliações públicas de usuários da Steam. Inicialmente, foram analisadas a estrutura dos dados, a distribuição das recomendações, os idiomas disponíveis e o período das avaliações. Essa etapa permitiu compreender as principais características da base e identificar os recortes necessários para definir o conjunto de dados utilizado nas etapas posteriores.

4.2.2. Análise das avaliações textuais

Foi analisado o tamanho das avaliações por meio da quantidade de palavras presentes em cada texto. Essa análise permitiu identificar a extensão das opiniões dos usuários e observar a existência de avaliações muito curtas. Neste momento, os textos não foram removidos, pois a análise teve como objetivo apenas compreender as características das avaliações e auxiliar nas decisões das etapas posteriores de preparação dos dados.

Figura 1: Distribuição da quantidade de palavras nas avaliações textuais



4.2.3. Definição da base de análise

Após a análise inicial, foi definido o recorte utilizado no projeto, considerando exclusivamente as avaliações em inglês disponíveis entre os anos de 2010 e 2025. Esse período foi mantido por abranger todo o intervalo temporal selecionado na base e permitir a utilização de uma quantidade maior de avaliações para as etapas de análise e modelagem.

4.2.4. Resumo da base

Após os processos de seleção e validação, foram selecionadas 19.487 avaliações em inglês, abrangendo o período de 2010 a 2025. A variável **voted_up** foi utilizada para identificar as recomendações positivas e negativas dos usuários, servindo como variável-alvo para os modelos de classificação. Após a limpeza dos textos, 262 avaliações ficaram sem conteúdo e foram removidas. Dessa forma, a base final utilizada na modelagem ficou composta por 19.225 avaliações.

4.3. Tratamento e Preparação dos Dados

4.3.1. Limpeza e normalização

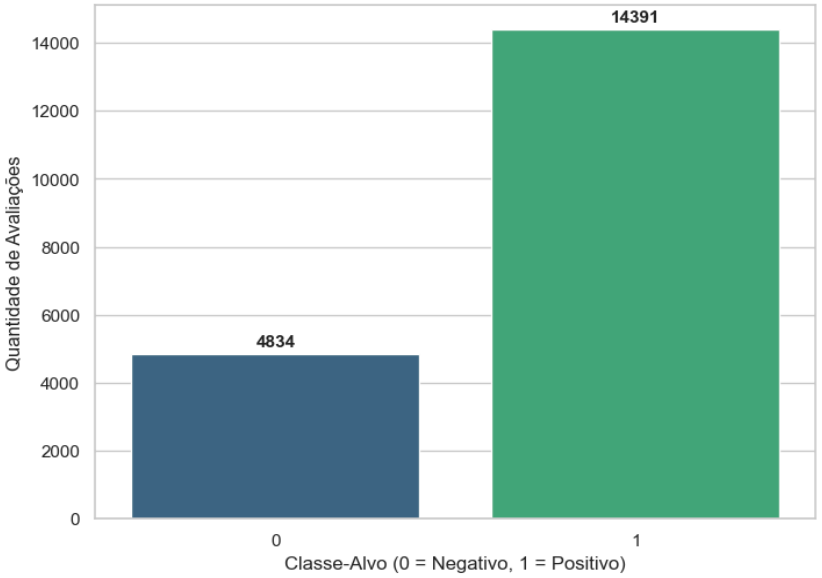
As avaliações textuais passaram por um processo de limpeza e normalização para padronizar os dados utilizados na modelagem. Os textos foram convertidos para letras minúsculas e foram removidas URLs, caracteres desnecessários e espaços extras. As stopwords não foram removidas nesta etapa, pois algumas palavras podem contribuir para a identificação do sentimento ou da recomendação presente nas avaliações.

4.3.2. Preparação da variável-alvo

A variável **voted_up**, responsável por indicar se o usuário recomendou o jogo, foi utilizada como variável-alvo dos modelos de classificação. Para facilitar o processamento, os valores foram convertidos para uma representação numérica, em que **1** corresponde a uma recomendação positiva e **0** a uma recomendação negativa. Após a limpeza dos textos, a

base utilizada na modelagem ficou composta por 19.225 avaliações, sendo 14.391 positivas (74,86%) e 4.834 negativas (25,14%).

Figura 2: Proporção das recomendações positivas (1) e negativas (0)



4.3.3. Preparação para modelagem

Após as etapas de limpeza, os dados foram organizados para a aplicação dos métodos de classificação. A variável **review limpa** passou a representar o conteúdo textual utilizado como entrada dos modelos, enquanto a variável alvo representa a classe a ser prevista. Também foram removidas 262 avaliações que ficaram sem conteúdo após a limpeza, resultando em 19.225 registros disponíveis para as etapas de vetorização e modelagem.

5. MODELAGEM E AVALIAÇÃO

5.1. Bases Teóricas dos Métodos Analíticos

5.1.1. TF-IDF

Para transformar as avaliações textuais em dados que possam ser utilizados pelos modelos de classificação, foi aplicada a técnica TF-IDF (Term Frequency-Inverse Document Frequency). O método atribui pesos aos termos de acordo com sua frequência e relevância nos documentos,

permitindo representar os textos numericamente. No projeto, a configuração inicial considerou palavras individuais e combinações de duas palavras, com limite de 5.000 características. Em uma etapa posterior, foi realizada uma busca de parâmetros para a Regressão Logística e o Complement Naive Bayes, na qual ambos selecionaram 10.000 características. A vetorização foi ajustada somente com os dados de treinamento, evitando o uso de informações do conjunto de teste.

Cada avaliação passa a ser representada por um vetor numérico em que cada posição corresponde a um termo (palavra ou par de palavras) e recebe um peso: termos presentes em poucas avaliações, como “refund” ou “boring”, recebem peso maior do que termos presentes em quase todos os textos, como “the”. São esses vetores que os classificadores recebem como entrada (X) para prever a variável-alvo (1 =recomenda, 0 = não recomenda). As stopwords foram mantidas porque termos como “not” e “no” carregam o sentido da opinião, e os pares de palavras preservam construções como “not good” ou “not worth”.

5.1.2. Classificação supervisionada

O projeto utiliza classificação supervisionada, na qual os modelos aprendem a partir de dados que possuem uma variável-alvo conhecida. Neste caso, as avaliações textuais representam os dados de entrada e a variável **voted_up**, posteriormente convertida para 0 e 1, representa a classe a ser prevista. Foram selecionados três modelos para identificar se uma avaliação corresponde a uma recomendação positiva ou negativa: Multinomial Naive Bayes, Regressão Logística e Random Forest.

5.1.3. Multinomial Naive Bayes

O Multinomial Naive Bayes é um classificador probabilístico. Para cada avaliação, ele calcula a probabilidade de pertencer a cada classe combinando dois elementos: a probabilidade a priori da classe (cerca de 74,86% positiva e 25,14% negativa no treino) e a probabilidade de cada

termo aparecer em avaliações daquela classe, estimada a partir dos pesos TF-IDF dos textos de treinamento. A classe com maior probabilidade é a prevista. O modelo supõe que os termos são independentes entre si, o que simplifica o cálculo, e, como a probabilidade a priori favorece a classe positiva, tende a classificar avaliações duvidosas como positivas. Na etapa de ajuste, foi utilizada a variante Complement Naive Bayes, mais adequada a bases desbalanceadas.

5.1.4. Regressão Logística

A Regressão Logística atribui um peso a cada termo do vocabulário TF-IDF e combina esses pesos, de acordo com a importância do termo em cada avaliação, para calcular a probabilidade de a avaliação ser positiva. Termos com peso positivo (como “great” ou “fun”) aumentam essa probabilidade; termos com peso negativo (como “refund” ou “boring”) a diminuem. Por padrão, a avaliação é classificada como positiva quando a probabilidade é de pelo menos 0,50, valor chamado de limiar de decisão. Os pesos são aprendidos nos dados de treinamento, com regularização para evitar ajuste excessivo. Uma vantagem do modelo é que os pesos podem ser lidos, o que permite identificar os termos mais associados a cada classe.

5.1.5. Random Forest

O Random Forest combina diversas árvores de decisão (100 na configuração inicial e 200 na ajustada). Cada árvore é treinada com uma amostra diferente dos dados e, em cada divisão, considera apenas um subconjunto dos termos, fazendo perguntas como “o termo X aparece com peso acima de determinado valor?”. A classe final é definida por votação das árvores. Como a representação TF-IDF é muito esparsa (a maioria dos termos tem peso zero em cada avaliação), as árvores tendem a ser menos eficientes do que os modelos lineares nesse tipo de dado.

5.1.6. Aplicação dos métodos

Após a preparação dos textos e a vetorização por TF-IDF, os três modelos selecionados foram treinados utilizando o conjunto de dados de treinamento. Em seguida, foram realizadas previsões sobre o conjunto de teste, mantendo os dados de teste separados durante o treinamento.

Dessa forma, foi possível utilizar o mesmo conjunto de avaliação para comparar o desempenho do Multinomial Naive Bayes, da Regressão Logística e do Random Forest. Os dados foram divididos em 80% para treinamento e 20% para teste. Foi utilizada estratificação para manter a proporção das classes nos dois conjuntos, com **random_state** definido como 42.

Para evitar vazamento de informação, a separação entre treino e teste foi feita antes de qualquer ajuste. O TF-IDF foi ajustado somente com os textos de treinamento e apenas aplicado ao teste. A busca de parâmetros e a escolha do limiar utilizaram exclusivamente os dados de treinamento, por validação cruzada estratificada de 5 partes, com o TF-IDF dentro do pipeline (reajustado a cada rodada). O conjunto de teste foi usado uma única vez, na avaliação final de cada modelo. Como limitação, os 384 textos duplicados identificados na base não foram removidos, de modo que alguns textos repetidos podem aparecer tanto no treino quanto no teste (cerca de 3,7% do teste), o que pode elevar levemente as métricas.

5.2. Cálculo da Acurácia e Métricas de Avaliação

5.2.1. Treinamento e previsão

Os modelos Multinomial Naive Bayes, Regressão Logística e Random Forest foram treinados utilizando os dados de treinamento previamente preparados e vetorizados pelo TF-IDF. Após o treinamento, cada modelo realizou previsões sobre o conjunto de testes, permitindo calcular as

métricas de desempenho e analisar a capacidade de classificação das avaliações entre recomendações positivas e negativas.

5.2.2. Acurácia e avaliação

A avaliação dos modelos foi realizada utilizando as métricas de acurácia, precisão, recall e F1-Score. Essas medidas permitem analisar o desempenho geral da classificação e a capacidade de identificar corretamente as recomendações positivas e negativas.

Para a modelagem, os textos das avaliações foram transformados em representações numéricas por meio do TF-IDF. A variável voted_up foi utilizada como variável-alvo, indicando se a avaliação representa uma recomendação positiva ou negativa. A base foi dividida em 80% para treinamento e 20% para teste, com estratificação para preservar aproximadamente a proporção entre as classes. O conjunto de teste foi mantido separado durante o treinamento e a seleção dos parâmetros.

Inicialmente, foram comparados três modelos: Multinomial Naive Bayes, Regressão Logística e Random Forest. Na comparação original, o Multinomial Naive Bayes apresentou acurácia de 84,08% e F1-Score de 90,26%. A Regressão Logística obteve acurácia de 86,29% e F1-Score de 91,31%, enquanto o Random Forest apresentou acurácia de 82,89% e F1-Score de 89,51%.

Como a base possui mais avaliações positivas do que negativas, a acurácia isolada não é suficiente para avaliar o desempenho dos modelos. Por esse motivo, também foram analisadas as métricas por classe, especialmente o F1-Score macro, que atribui o mesmo peso às duas classes.

Para saber se os resultados são realmente bons, foi criado um modelo de referência que sempre responde “positiva”. Ele atinge acurácia de cerca de 75% sem aprender nada, mas tem recall de 0% na classe negativa e F1 macro de 42,8%. Isso confirma que a acurácia sozinha

engana nesta base e que um modelo útil precisa superar a referência na classe negativa.

Na comparação inicial, a classe negativa foi o ponto fraco: o recall negativo foi de 41,05% (Multinomial Naive Bayes), 56,77% (Regressão Logística) e 39,40% (Random Forest), e o F1 macro foi de 73,37%, 79,44% e 71,58%, respectivamente.

Em seguida, foram testados ajustes voltados à classe negativa, todos escolhidos apenas com os dados de treinamento, por validação cruzada de 5 partes, maximizando o F1 macro: (i) pesos de classe balanceados (class_weight="balanced") na Regressão Logística e no Random Forest; (ii) uso do Complement Naive Bayes; (iii) busca de parâmetros (ngram_range, max_features e C ou alpha). Para a Regressão Logística, a busca selecionou C=5, 10.000 características e combinações de uma e duas palavras (F1 macro de 83,21% na validação cruzada). Para o Naive Bayes, selecionou alpha=1,0 com 10.000 características (80,79%).

Por fim, foi avaliado o limiar de decisão da Regressão Logística, também por validação cruzada nos dados de treinamento. O limiar de 0,45 apresentou o maior F1 macro entre os valores testados. Com esse limiar, o conjunto de teste apresentou acurácia de 87,28% e F1 macro de 83,33%. Para a classe negativa, a precisão foi de 73,76%, o recall de 76,73% e o F1-Score de 75,22%. Para a classe positiva, a precisão foi de 92,07%, o recall de 90,83% e o F1-Score de 91,45%.

O principal ganho na identificação das avaliações negativas veio dos pesos de classe e da busca de parâmetros: o recall negativo da Regressão Logística passou de 56,77% para cerca de 81% já com o limiar padrão de 0,50. O limiar de 0,45 teve efeito pequeno (o F1 macro ficou praticamente igual) e apenas redistribuiu os erros entre as classes, trocando parte do recall negativo por maior precisão.

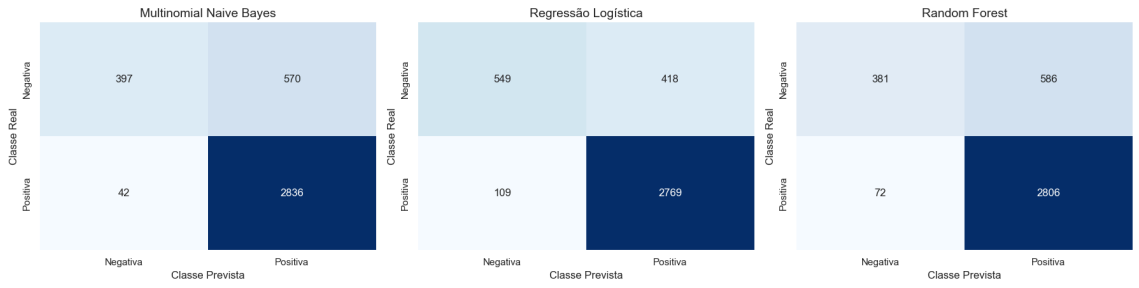
5.2.3. Matriz de confusão

A matriz de confusão permite comparar as classificações previstas pelo modelo com as classificações reais das avaliações.

Na comparação inicial, a Regressão Logística identificou corretamente 549 avaliações negativas e 2.769 positivas, apresentando melhor desempenho na identificação das avaliações negativas em relação aos outros modelos.

Após os ajustes, com a Regressão Logística e o limiar de 0,45, o modelo final identificou corretamente 742 avaliações negativas e 2.614 positivas (Figura 6, apresentada na seção 5.2.5). Houve 225 avaliações negativas classificadas como positivas e 264 positivas classificadas como negativas. Em comparação com a modelagem inicial (549 negativas corretas), a identificação das avaliações negativas melhorou de forma expressiva, embora ainda ocorram erros nas duas classes.

Figura 3: Matrizes de Confusão dos Modelos Avaliados



5.2.4. Avaliação por classe

A avaliação por classe permitiu analisar o desempenho dos modelos na identificação das recomendações positivas e negativas. Na comparação inicial, os três modelos apresentaram maior facilidade para identificar avaliações positivas.

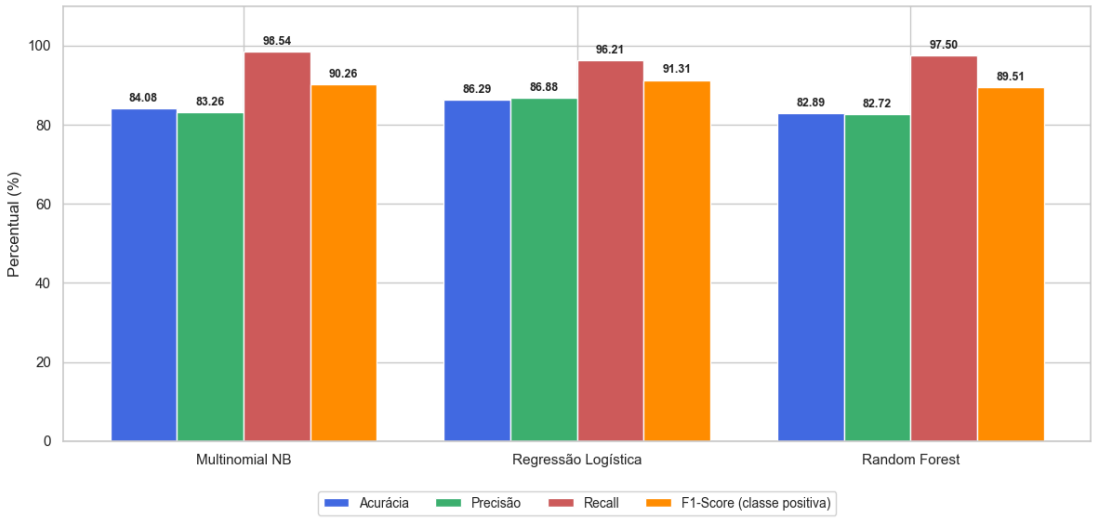
No modelo final (Regressão Logística ajustada, limiar 0,45), o recall foi de 76,73% para a classe negativa e 90,83% para a positiva. O F1-Score foi de 75,22% para as avaliações negativas e 91,45% para as positivas.

Em relação à comparação inicial, em que o recall negativo variava entre 39,40% e 56,77%, houve melhora clara na identificação das avaliações negativas, resultado principalmente dos pesos de classe e da busca de parâmetros. Ainda assim, o desempenho na classe negativa permanece inferior ao da classe positiva.

5.2.5. Comparação dos resultados

Na comparação inicial, a Regressão Logística apresentou a maior acurácia (86,29%), seguida pelo Multinomial Naive Bayes (84,08%) e pelo Random Forest (82,89%). Atenção: os valores de F1-Score da Figura 4 referem-se à classe positiva e não devem ser comparados diretamente com o F1 macro, que é calculado de outra forma.

Figura 4: Comparação Inicial do Desempenho dos Modelos



Como a acurácia é limitada pelo desbalanceamento da base, a comparação antes e depois dos ajustes foi feita pelo F1 macro, pelo F1 e pelo recall da classe negativa (Figura 5):

Modelo	F1 macro	F1 negativa	Recall negativa
Referência (sempre positiva)	42,8%	0,0%	0,0%
Naive Bayes (inicial)	73,4%	56,5%	41,1%
Reg. Logística (inicial)	79,4%	67,6%	56,8%
Random Forest (inicial)	71,6%	53,7%	39,4%
Complement NB (ajustado)	80,0%	71,8%	83,8%
Reg. Logística (ajustada, limiar 0,50)	83,3%	75,7%	81,0%
Random Forest (ajustado)	78,6%	68,0%	68,0%

Figura 5: Comparação antes e depois dos ajustes

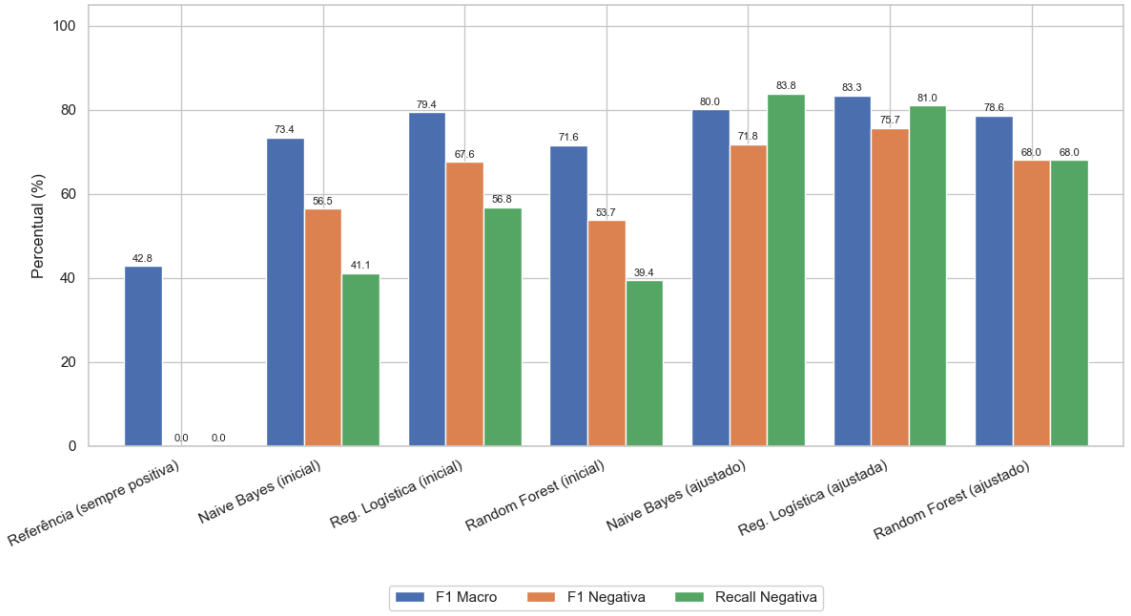
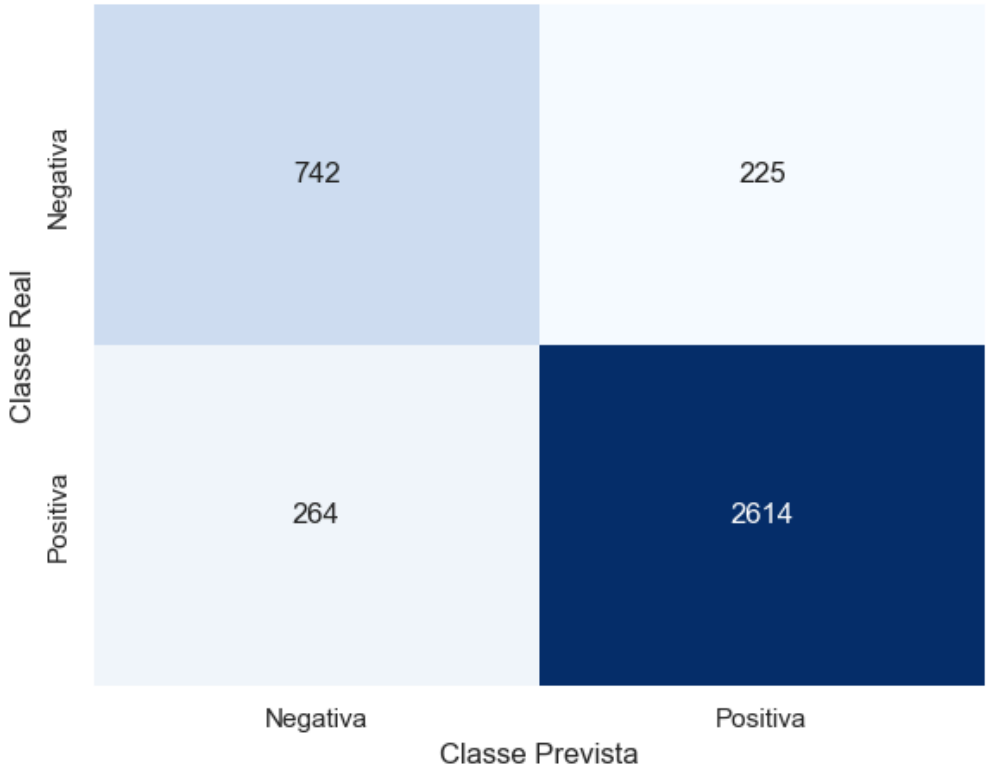


Figura 6: Matriz de confusão do modelo final



Nota: na Figura 5, “Naive Bayes (ajustado)” corresponde ao Complement Naive Bayes e “Reg. Logística (ajustada)” ao limiar padrão de 0,50. A Figura 6 mostra o modelo final, com limiar de 0,45.

Todos os modelos ajustados melhoraram em relação à versão inicial, e a Regressão Logística ajustada obteve o melhor F1 macro. Ela foi escolhida como modelo final com base no F1 macro da validação cruzada (83,21%), e não nos resultados do teste. Com o limiar de 0,45, o modelo final alcançou acurácia de 87,28% e F1 macro de 83,33% no conjunto de teste.

Em relação à meta do projeto (F1-Score de pelo menos 80%), ela foi atingida considerando o F1 macro (83,33%) e o F1 da classe positiva (91,45%). Na classe negativa, porém, o F1-Score foi de 75,22%, abaixo da meta, o que indica espaço para melhoria.

Os resultados indicam que a Regressão Logística é uma alternativa promissora para classificar as avaliações da Steam. Entretanto, a escolha do modelo deve considerar o desempenho nas duas classes, especialmente na identificação das avaliações negativas.

5.3. Produto Analítico e Modelo de Negócios

5.3.1. Descrição do Produto Analítico

O produto analítico proposto pela GameInsight Studios consiste em uma solução de classificação automatizada de avaliações de jogos da Steam, utilizando NLP e Machine Learning. O produto gerado nesta etapa tem dois componentes: (1) o modelo de classificação treinado (Regressão Logística com TF-IDF e limiar de 0,45), que prevê, a partir do texto de uma avaliação, se ela corresponde a uma recomendação positiva ou negativa; e (2) a análise dos termos mais associados a cada classe, obtida a partir dos pesos do próprio modelo.

Na análise de termos, os que mais empurram a avaliação para a classe negativa incluem “boring”, “not worth”, “waste”, “awful”, “terrible”, “refund”, “buggy”, “unplayable” e “scam”, o que sugere queixas sobre conteúdo, custo-benefício e problemas técnicos. Os termos mais associados à classe positiva incluem “great”, “fun”, “love”, “amazing”,

“best” e “awesome”. Essa leitura permite a uma desenvolvedora identificar rapidamente os principais motivos de insatisfação sem ler todos os comentários.

Nos testes realizados, o modelo final alcançou acurácia de 87,28% e F1 macro de 83,33% no conjunto de teste, com recall de 76,73% para a classe negativa e de 90,83% para a positiva, o que mostra que ainda há oportunidade de melhoria na identificação das avaliações negativas.

Como evolução do produto, propõe-se desenvolver um painel analítico para apresentar a distribuição das avaliações, comparar indicadores entre jogos e facilitar a identificação de possíveis pontos de insatisfação. Essas funcionalidades representam possibilidades futuras e não fazem parte do produto já implementado.

5.3.2. Proposta de modelo de negócios

A GameInsight Studios poderá direcionar a solução a desenvolvedoras e publicadoras de jogos que desejem compreender melhor as opiniões dos jogadores.

O modelo de negócios proposto considera a oferta de análises automatizadas das avaliações, com possibilidade de disponibilização de relatórios periódicos ou acesso a uma plataforma analítica por assinatura.

A proposta de valor consiste em reduzir o esforço necessário para organizar grandes volumes de comentários e facilitar a identificação de padrões de satisfação e insatisfação. Essas informações poderão apoiar investigações sobre a experiência dos jogadores e orientar decisões relacionadas à melhoria dos produtos.

O modelo é conceitual e ainda precisa ser validado quanto à demanda, à viabilidade técnica e à disposição dos potenciais clientes em pagar pela solução.

5.4. Esboço do Storytelling

5.4.1. Contextualização do problema

A plataforma Steam reúne um grande volume de avaliações textuais publicadas pelos jogadores. Embora esses comentários contenham informações relevantes sobre a experiência com os jogos, a análise manual de grandes quantidades de avaliações pode dificultar a identificação de padrões de opinião e de possíveis pontos de insatisfação.

Diante desse cenário, a GameInsight Studios propõe utilizar técnicas de Processamento de Linguagem Natural (NLP) e Machine Learning para classificar automaticamente as avaliações em recomendações positivas e negativas.

5.4.2. Análise dos dados e desenvolvimento da solução

O projeto utilizou inicialmente 19.487 avaliações em inglês, publicadas entre 2010 e 2025. Após a limpeza textual, 262 registros que ficaram sem conteúdo foram removidos, resultando em uma base de 19.225 avaliações para a modelagem.

A análise identificou que 74,86% das avaliações eram positivas e 25,14% negativas. Essa distribuição demonstrou a importância de avaliar o desempenho dos modelos nas duas classes, evitando que a análise se limitasse à acurácia geral.

Para desenvolver a solução, foram aplicadas técnicas de TF-IDF e comparados três modelos de classificação: Multinomial Naive Bayes, Regressão Logística e Random Forest.

5.4.3. Principais resultados e descoberta

Na comparação inicial, a Regressão Logística apresentou a maior acurácia (86,29%), mas todos os modelos tiveram dificuldade com as

avaliações negativas (recall entre 39,40% e 56,77%). Para corrigir isso, foram aplicados pesos de classe balanceados, busca de parâmetros por validação cruzada e ajuste do limiar de decisão (0,45), sempre usando apenas os dados de treinamento.

Com esses ajustes, o modelo final (Regressão Logística) alcançou acurácia de 87,28% e F1 macro de 83,33% no conjunto de teste, acima da meta de 80% e muito acima do modelo de referência (F1 macro de 42,8%). O recall foi de 90,83% para as avaliações positivas e 76,73% para as negativas.

Além disso, a análise dos pesos do modelo mostrou que termos como “boring”, “waste”, “refund”, “buggy” e “unplayable” estão entre os mais associados a recomendações negativas. Os resultados indicam que o modelo tem potencial para classificar avaliações automaticamente, mas ainda encontra maior dificuldade para identificar recomendações negativas, o que representa uma oportunidade de melhoria para as próximas etapas.

5.4.4. Aplicação prática e próximos passos

A solução proposta poderá ajudar desenvolvedoras e publicadoras de jogos a organizar grandes volumes de avaliações e identificar padrões de satisfação e insatisfação dos jogadores.

Como próximos passos, propõe-se aprimorar o desempenho na identificação das avaliações negativas e desenvolver recursos de visualização que facilitem a interpretação dos resultados. Dessa forma, a GameInsight Studios poderá evoluir de um modelo experimental de classificação para uma solução analítica que apoie a compreensão da experiência dos jogadores.

6. REPOSITÓRIO DO PROJETO

O projeto é desenvolvido de forma colaborativa, com os arquivos organizados em um repositório no GitHub. Nele, estão disponíveis os notebooks, códigos, gráficos e demais materiais utilizados no desenvolvimento e na avaliação dos modelos.

Repositório: **Projeto Classificações das Avaliações**

7. CONSIDERAÇÕES FINAIS

O projeto aplicou técnicas de NLP e Machine Learning para classificar avaliações da Steam em positivas e negativas. Após a limpeza dos textos, foram utilizadas 19.225 avaliações para a modelagem.

Na comparação inicial, a Regressão Logística apresentou a maior acurácia, com 86,29%, mas todos os modelos tiveram baixo recall na classe negativa. Com pesos de classe balanceados, busca de parâmetros e ajuste do limiar para 0,45, a Regressão Logística alcançou acurácia de 87,28% e F1 macro de 83,33% no conjunto de teste, atingindo a meta de 80% de F1-Score (F1 macro), embora o F1-Score da classe negativa (75,22%) ainda esteja abaixo dela.

O modelo ainda apresenta dificuldades para identificar parte das avaliações negativas (recall de 76,73%). Isso demonstra a importância de analisar diferentes métricas, além da acurácia, para avaliar a qualidade da classificação. Como limitação, os textos duplicados não foram removidos e podem aparecer tanto no treino quanto no teste.

Como próximos passos, o projeto poderá explorar melhorias no pré-processamento dos textos, testar outras configurações dos modelos, remover textos duplicados e avaliar novas estratégias para aumentar o desempenho na identificação das avaliações negativas.

8. REFERÊNCIAS

VINTAGEDON. Steam Dataset 2025: Multi-Modal Gaming Analytics Platform. GitHub Repository, 2025. Disponível em: https://github.com/vintagedon/steam-dataset-2025/data/01_raw at main · vintagedon/steam-dataset-2025 . Acesso em: 26 ago. 2026.

VALVE CORPORATION. Steam Community and Platform Overview. Valve, 2026. Disponível em: https://store.steampowered.com. Acesso em: 26 ago. 2026.

GOOGLE CLOUD. O que é Machine Learning?. Google Cloud, 2026. Disponível em: https://cloud.google.com/learn/what-is-machine-learning?hl=pt-BR. Acesso em: 26 ago. 2026.